

VectorDB & RAG

VLDB Lab.


Professor Sangwon Lee

Contents

- RDBMS v.s. Vector Database
- RAG란?
- ChromaDB란?
- ChromaDB Getting Started
- RAG System 실습


Relational Database Management System (RDBMS)

- 테이블 형태로 정보를 저장하는 데이터베이스



Relational Database Management System (RDBMS)

- 테이블 형태로 정보를 저장하는 데이터베이스



Other Database Systems

- NoSQL  mongoDB  Couchbase


- Cloud Data Warehouse Solution



- Etc.

Vector Database: When and Why

- **벡터란?** 데이터 객체의 수치 표현
- **벡터 임베딩:** 단어와 문장, 기타 데이터를 의미와 관계를 포착하는 숫자로 변환하는 방법




나는	[1, 0, 0, 0, 0]
임베딩	[0, 1, 0, 0, 0]
공부를	[0, 0, 1, 0, 0]
하고	[0, 0, 0, 1, 0]
있다	[0, 0, 0, 0, 1]

나는	[0.123, -0.411, 0.345, 0.198, 0.757]
임베딩	[0.841, 0.742, 0.956, 0.312, 0.149]
공부를	[2.314, 0.742, 1.233, 0.534, -0.015]
하고	[-1.434, 0.742, 0.231, 0.864, 0.508]
있다	[0.389, 0.742, 1.412, 1.218, -1.113]

Vector Database: When and Why


- 벡터 데이터베이스

- 정보를 벡터로 저장하는 데이터베이스.
- 이러한 벡터를 기반으로 유사성 검색(Similarity Search)과 같은 작업을 효율적으로 수행할 수 있도록 설계된 데이터베이스



Vector Database: When and Why

- VectorDB: 고차원 벡터 데이터를 저장, 관리, 인덱싱하는 데이터베이스
- 각 벡터와 함께 메타데이터 (제목, 설명 등)을 함께 저장함.
- 벡터 임베딩에 대한 인덱스를 생성하여, 고차원 데이터 공간 내에서 벡터 검색을 가속화함.
- 쿼리 벡터와 가장 유사한 벡터 또는 가장 가까운 이웃 (Nearest Neighbors)을 다양한 유사도 기준 (코사인 유사도 등)에 따라 검색함.




<https://qdrant.tech/articles/what-are-embeddings/>

- <https://www.ibm.com/think/topics/vector-database>

Vector Database: When and Why

- 벡터 데이터베이스에서 쿼리는 무엇이고, 어떤 데이터를 반환하는 걸까?
 1. 벡터 쿼리 생성: 사용자가 검색하려는 내용이나 질문의 벡터 형태의 쿼리 생성
 2. 벡터 유사성 검색: 벡터 데이터베이스에서는 쿼리 벡터와 저장된 벡터 간의 유사성 계산(코사인 유사도, 유클리드 거리 계산 등)
 3. 쿼리 수행: 사용자가 쿼리를 제출하면, 벡터 데이터베이스는 저장된 벡터와 쿼리 벡터 간의 유사성을 계산




Retrieval Augmented Generation (RAG)

- LLM의 한계점


- 학습 데이터에 기반한 parametric knowledge에 한정되어 있어, 오래되거나 잘못된 정보를 제공할 수 있음.
- 사용자가 회사 고유 데이터나 문맥에 특화된 답변을 기대할 때, 일반적인 정보만 제공하는 경우가 많음.

Retrieval-Augmented Generation (RAG)

- 생성형 모델과 검색 기반 모델을 결합한 자연어 처리 접근 방식
- 정보 검색과 텍스트 생성을 통합하여 보다 풍부하고 정확한 답변을 생성하는데 중점을 둠.



Retrieval Augmented Generation (RAG)




<https://www.promptingguide.ai/kr/research/rag>


• RAG의 장점

- LLM이 외부 지식 소스에 접근할 수 있게 됨.
- 따라서 모델 내부 파라미터에 포함되지 않은 정보도 검색하고 활용 가능

VectorDB + RAG




Timeline



ChromaDB

- AI-Native Open Source Vector Database
- 플러그형으로 만들어 LLM application을 쉽게 구축할 수 있도록 함.



ChromaDB Getting Started

<https://docs.trychroma.com/docs/overview/getting-started>

Install

Command Line

Copy Code

```
1 pip install chromadb
```

Create a Chroma Client

python

Copy Code

```
1 import chromadb
2 chroma_client = chromadb.Client()
```

Create a Collection **Collection: 벡터 데이터를 저장하는 기본 단위

python

Copy Code

```
1 collection = chroma_client.create_collection(name="my_collection")
```

ChromaDB Getting Started

<https://docs.trychroma.com/docs/overview/getting-started>

Add some text documents to the collection

</> python

Copy Code

```
1 collection.add(
2     documents=[
3         "This is a document about pineapple",
4         "This is a document about oranges"
5     ],
6     ids=["id1", "id2"]
7 )
```

Query the collection

</> python

Copy Code

```
1 results = collection.query(
2     query_texts=["This is a query document about hawaii"], # Chroma will embed this
3     n_results=2 # how many results to return
4 )
5 print(results)
```